

PROGRAMME DE FORMATION · VERSION 3 · 2026-09-13

Data Engineering cloud : pipelines ELT et orchestration

Concevez un pipeline ELT incrémental capable d'absorber retards, doublons et reprises. Les ateliers relient contrats de données, transformations, orchestration et exploitation jusqu'à une livraison documentée.

3 jours · 21 heures

Avancé · Hybride

2 190 € HT

Tarif indicatif, dates, disponibilité et modalités contractuelles à confirmer avec le centre.

À qui s'adresse cette formation ?

Data engineers, développeurs data, responsables integration, architectes cloud data.

Prérequis

Avoir des bases en SQL, integration et manipulation de données.

Objectifs pédagogiques

- Concevoir des pipelines cloud robustes et réutilisables
- Mettre en place supervision, logs et qualité de service
- Mieux articuler data engineering, BI et usages IA

Le cas fil rouge

Concevoir un pipeline de commandes quotidiennes capable de reprendre après panne et de réconcilier ses résultats avec la source.

Préparation

SQL, Python et bases cloud ; simulations locales d'API et de stockage, comptes cloud facultatifs pour la démonstration.

Progression détaillée

Répartition pédagogique proposée sur une base de 7 heures par jour, pauses exclues. À ajuster avec le formateur au positionnement initial. Les approfondissements « Pour aller plus loin » sont sélectionnés par le formateur selon le positionnement et le temps disponible ; ils ne constituent pas des heures supplémentaires garanties.

Jour 1 · 7 heures

1. Définir contrats et architecture ELT

210 minutes · apports, exercice et retour

- Identifier volumes, fraîcheur, schémas et règles de conservation.
- Séparer ingestion brute, transformation et exposition analytique.
- Comparer batch, micro-batch et capture de changements selon le besoin.

- Préciser granularité, schéma, clés, SLA de fraîcheur, responsabilité des sources et règles d'évolution des contrats.

NOTIONS ET MÉTHODES EN DÉTAIL

- Définir grain, clés, schéma, fraîcheur et compatibilité du contrat de données source.
- Séparer zones brutes, données préparées et tables d'usage ; attribuer chaque responsabilité.
- Choisir batch ou incrémental selon latence, coût et capacités réelles de la source.

Atelier prévu

Écrire le contrat d'une source commandes et dessiner le chemin vers les tables analytiques, avec responsabilités et délais attendus.

Livrable attendu

Architecture ELT et contrats de données versionnés.

Vérification en atelier

Le flux décrit clés, fréquence, propriétaire et contrôle à chaque passage.

Pour aller plus loin · selon positionnement et temps disponible

Comparer batch, micro-batch et CDC selon le volume, la latence attendue, le coût et les capacités de reprise.

2. Ingérer de manière incrémentale

210 minutes · apports, exercice et retour

- Gérer pagination, quotas, dates de modification et marqueurs de reprise.
- Traiter suppressions, événements tardifs et évolutions de schéma.
- Conserver données brutes et métadonnées d'exécution.
- Gérer watermark, CDC, suppressions, événements tardifs, doublons et changements de schéma sans perdre la traçabilité.

NOTIONS ET MÉTHODES EN DÉTAIL

- Comparer watermark, journal de changements et extraction complète sur une source de démonstration.
- Traiter retards et doublons ; choisir fenêtre de recouvrement et clé d'idempotence.
- Conserver métadonnées et point de reprise sans avancer le curseur après un échec.

Atelier prévu

Simuler deux extractions avec chevauchement et vérifier que la seconde n'ajoute pas de doublons ni n'oublie une correction tardive.

Livrable attendu

Connecteur incrémental, journal de rejets et protocole de reprise.

Vérification en atelier

Un lot rejoué ne crée pas de doublon et une donnée tardive est intégrée.

Pour aller plus loin · selon positionnement et temps disponible

Rejouer une plage temporelle après incident et démontrer l'idempotence du chargement sur des données déjà présentes.

Jour 2 · 7 heures

3. Transformer et contrôler les tables

210 minutes · apports, exercice et retour

- Construire couches nettoyées et agrégées avec dépendances explicites.
- Tester unicité, nullité, références et rapprochement des montants.
- Isoler les rejets et documenter les règles de correction.
- Construire des transformations modulaires avec tests de clés, de relations, de complétude et de fraîcheur.

NOTIONS ET MÉTHODES EN DÉTAIL

- Décomposer les transformations en modèles lisibles avec dépendances, types et conventions.
- Écrire tests d'unicité, non-nullité, relations et rapprochement de totaux aux frontières critiques.
- Isoler les rejets avec motif ; distinguer erreur bloquante et anomalie tolérée.

Atelier prévu

Assembler clients et commandes ; produire un rapport distinguant données acceptées, mises en quarantaine et erreurs bloquantes.

Livrable attendu

Modèles de transformation, tests de données et documentation du lignage.

Vérification en atelier

Les rejets sont traçables et les totaux concordent avec le périmètre accepté.

Pour aller plus loin · selon positionnement et temps disponible

Comparer reconstruction complète et modèle incrémental, puis traiter une correction tardive modifiant un historique déjà calculé.

4. Orchestrer et rejouer les traitements

210 minutes · apports, exercice et retour

- Définir tâches, dépendances, retries et délais maximaux.
- Rendre les écritures idempotentes et gérer les exécutions concurrentes.
- Rejouer une période historique sans écraser des données récentes.
- Exprimer dépendances, états d'exécution, retries, backoff, paramètres et limites de concurrence dans le DAG.

NOTIONS ET MÉTHODES EN DÉTAIL

- Construire un DAG sans dépendance implicite ; paramétrer date logique, retries et concurrence.
- Différencier nouvelle exécution, reprise partielle et backfill ; éviter les doubles écritures.
- Tester timeout et indisponibilité d'une tâche amont avec reprise depuis un état connu.

Atelier prévu

Provoquer une panne intermédiaire, relancer le flux et vérifier les totaux après reprise puis après backfill.

Livrable attendu

DAG paramétrable et procédure de backfill testée.

Vérification en atelier

La reprise ne détruit pas de partition valide et ne duplique pas la cible.

Pour aller plus loin · selon positionnement et temps disponible

Concevoir un backfill borné qui évite doubles calculs, surcharge du système source et incohérence des tables aval.

Jour 3 · 7 heures

5. Exploiter et protéger la plateforme

210 minutes · apports, exercice et retour

- Suivre fraîcheur, volumes, durée, coûts et taux de rejet.
- Séparer identités techniques, secrets et droits par environnement.
- Dimensionner partitions et traitements à partir de mesures.
- Suivre volumes, erreurs, coûts et fraîcheur ; isoler les secrets et limiter les droits des identités techniques.

NOTIONS ET MÉTHODES EN DÉTAIL

- Associer fraîcheur, volume et durée à des seuils d'alerte orientés usage.
- Gérer identités de service, moindre privilège, chiffrement et secrets hors du code.
- Limiter lectures et stockage inutiles par partitionnement et conservation justifiés.

Atelier prévu

Diagnostiquer une rupture de fraîcheur et proposer une optimisation chiffrée sur des métriques de démonstration.

Livrable attendu

Tableau d'exploitation, budget de consommation et matrice des accès.

Vérification en atelier

Une alerte précise table, usage affecté et responsable.

Pour aller plus loin · selon positionnement et temps disponible

Analyser une rupture de SLA et arbitrer réduction du scan, partitionnement, parallélisme et fréquence d'exécution.

6. Livrer un pipeline maintenable

210 minutes · apports, exercice et retour

- Versionner code, configuration et transformations.
- Préparer recette, promotion entre environnements et retour arrière.
- Rédiger une procédure d'incident et un catalogue des dépendances.
- Séparer environnements, configurations et données de test ; prévoir validation automatique et promotion contrôlée.

NOTIONS ET MÉTHODES EN DÉTAIL

- Assembler configuration, tests et déploiement avec séparation des environnements.
- Rédiger contrat de service, procédure de reprise et inventaire des dépendances.
- Recetter donnée invalide, changement de schéma et reconstruction d'une période.

Atelier prévu

Restituer le pipeline commandes avec tests, journal de reprise et guide d'exploitation qu'un collègue peut suivre.

Livrable attendu

Dépôt livrable, dossier d'exploitation et recette de reprise.

Vérification en atelier

Le pipeline passe le nominal et les trois scénarios de reprise documentés.

Pour aller plus loin · selon positionnement et temps disponible

Faire reprendre le pipeline par un tiers à partir du dépôt, du runbook et d'un incident simulé documenté.

Évaluation finale

Mise en situation individuelle et restitution commentée, incluses dans la dernière séquence. Durée indicative : 60 minutes.

- Une reprise ne crée ni pertes ni doublons.
- Les écarts entre source et cible sont expliqués.
- Les alertes et les coûts sont associés à des seuils opérationnels.

Méthodes et ressources

Apports illustrés, exercices progressifs, ateliers sur un cas fil rouge et retour argumenté sur les productions. Les ateliers et l'évaluation font partie des heures indiquées.

Les ateliers décrivent les travaux prévus. Leurs fichiers, corrigés et évaluations en ligne sont à préparer, sauf ressources explicitement disponibles dans le module pilote.

Accès, accompagnement et contact

Pour obtenir plus de détails ou le programme détaillé validé, contactez le centre : 09 54 70 23 80 — contact@beyondexpertise.eu.

Positionnement et vérification des prérequis avant inscription. Délais, calendrier et aménagements à convenir avec le centre. Pour un besoin d'accessibilité, décrivez le besoin pratique sans diagnostic médical.

Programme enrichi proposé, à valider par le formateur avant animation. Les approfondissements sont adaptés au niveau et au temps disponible. Aucune certification professionnelle ni prise en charge CPF ou OPCO n'est garantie. Démarche Qualiopi en cours ; certification non acquise.

Références pour approfondir

- [Apache Airflow](#) · conception des traitements
- [dbt](#) · tests de données