

PROGRAMME DE FORMATION · VERSION 3 · 2026-09-13

Feature Engineering et sélection de variables

Construisez des variables utiles sans introduire de fuite dans l'évaluation. Le cas pratique compare transformations et sélection dans un pipeline reproductible, avec attention à la stabilité et au coût de collecte.

2 jours · 14 heures

Avancé · Distanciel

1 690 € HT

Tarif indicatif, dates, disponibilité et modalités contractuelles à confirmer avec le centre.

À qui s'adresse cette formation ?

Data scientists, ML engineers, analystes avancés, profils IA.

Prérequis

Avoir déjà pratiqué un projet de machine learning avec Python.

Objectifs pédagogiques

- Créer des variables plus informatives pour les modèles
- Réduire le bruit et les variables non pertinentes
- Structurer un pipeline de préparation réutilisable

Le cas fil rouge

Améliorer un modèle tabulaire en construisant des variables utiles sans introduire d'information indisponible au moment de prédire.

Préparation

Python et premier modèle supervisé ; pandas, scikit-learn et données fictives de commandes.

Progression détaillée

Répartition pédagogique proposée sur une base de 7 heures par jour, pauses exclues. À ajuster avec le formateur au positionnement initial. Les approfondissements « Pour aller plus loin » sont sélectionnés par le formateur selon le positionnement et le temps disponible ; ils ne constituent pas des heures supplémentaires garanties.

Jour 1 · 7 heures

1. Auditer les variables et les fuites

210 minutes · apports, exercice et retour

- Définir instant de prédiction et date de disponibilité.
- Examiner distributions, valeurs manquantes et variables quasi constantes.
- Repérer variables directement ou indirectement dérivées de la cible.
- Vérifier disponibilité temporelle, identifiants, proxies et variables dérivées de la cible.

NOTIONS ET MÉTHODES EN DÉTAIL

- Identifier cible, moment de prédiction et disponibilité réelle de chaque variable.
- Repérer identifiants, agrégats futurs et transformations ajustées sur tout le jeu.
- Examiner valeurs manquantes, cardinalité et variables quasi constantes.

Atelier prévu

Auditer une table de scoring et retirer les informations connues seulement après l'événement prédit.

Livrable attendu

Audit des variables et règles d'exclusion.

Vérification en atelier

Les variables retenues sont disponibles au moment simulé de la décision.

Pour aller plus loin · selon positionnement et temps disponible

Repérer une fuite indirecte présente seulement après l'événement prédit.

2. Construire des transformations robustes

210 minutes · apports, exercice et retour

- Encoder catégories et gérer modalités inconnues.
- Imputer et normaliser dans le pipeline d'apprentissage.
- Créer variables temporelles et agrégats en respectant le passé disponible.
- Construire imputation, encodage, normalisation et agrégats dans les plis d'apprentissage.

NOTIONS ET MÉTHODES EN DÉTAIL

- Comparer imputation, mise à l'échelle et encodage selon type de variable et modèle.
- Ajuster transformations sur l'apprentissage uniquement avec Pipeline et ColumnTransformer.
- Traiter catégorie inconnue et valeur hors distribution à l'inférence.

Atelier prévu

Construire une transformation qui fonctionne sur données nouvelles avec catégorie inconnue et valeur manquante.

Livrable attendu

Transformations robustes et cas limites.

Vérification en atelier

Le pipeline traite un nouvel exemple sans réapprendre sur le jeu de test.

Pour aller plus loin · selon positionnement et temps disponible

Traiter une catégorie inconnue et une distribution différente en inférence.

Jour 2 · 7 heures

3. Sélectionner et comparer les variables

210 minutes · apports, exercice et retour

- Comparer filtres, régularisation et importance par permutation.
- Examiner corrélations et redondances.

- Ajuster sélection et transformations uniquement sur les folds d'entraînement.
- Comparer sélection filtrée, embarquée et permutation avec validation imbriquée si nécessaire.

NOTIONS ET MÉTHODES EN DÉTAIL

- Comparer filtre, sélection embarquée et importance par permutation sur une validation adaptée.
- Examiner redondance, corrélation et stabilité des variables entre plis.
- Prendre en compte coût, interprétabilité et disponibilité au-delà du seul score.

Atelier prévu

Comparer trois ensembles de variables avec validation identique et justifier le compromis entre qualité et simplicité.

Livrable attendu

Rapport de sélection et stabilité des résultats.

Vérification en atelier

La sélection est effectuée à l'intérieur du protocole de validation.

Pour aller plus loin · selon positionnement et temps disponible

Distinguer importance instable et variable réellement utile hors échantillon.

4. Livrer un pipeline réutilisable

210 minutes · apports, exercice et retour

- Assembler transformations dans Pipeline et ColumnTransformer.
- Tester stabilité, schéma et valeurs extrêmes.
- Documenter provenance et coût de calcul des variables.
- Assembler transformations et modèle avec contrat de schéma, tests et sérialisation.

NOTIONS ET MÉTHODES EN DÉTAIL

- Sérialiser transformations et modèle ensemble avec schéma d'entrée documenté.
- Ajouter tests sur colonnes absentes, ordre des colonnes et nouvelles catégories.
- Décrire hypothèses, limites et surveillance des variables utilisées.

Atelier prévu

Livrer le pipeline et un dictionnaire des variables avec date de disponibilité, règle de calcul et gain mesuré sur la baseline.

Livrable attendu

Pipeline réutilisable et tests de cohérence.

Vérification en atelier

Le pipeline rechargé reproduit les prédictions de référence.

Pour aller plus loin · selon positionnement et temps disponible

Garantir la même préparation en entraînement et en service.

Évaluation finale

Mise en situation individuelle et restitution commentée, incluses dans la dernière séquence. Durée indicative : 60 minutes.

- Les transformations n'apprennent pas sur le test.
- Le pipeline accepte des données nouvelles prévues par le contrat.
- Le gain est mesuré avec un protocole constant.

Méthodes et ressources

Apports illustrés, exercices progressifs, ateliers sur un cas fil rouge et retour argumenté sur les productions. Les ateliers et l'évaluation font partie des heures indiquées.

Les ateliers décrivent les travaux prévus. Leurs fichiers, corrigés et évaluations en ligne sont à préparer, sauf ressources explicitement disponibles dans le module pilote.

Accès, accompagnement et contact

Pour obtenir plus de détails ou le programme détaillé validé, contactez le centre : 09 54 70 23 80 — contact@beyondexpertise.eu.

Positionnement et vérification des prérequis avant inscription. Délais, calendrier et aménagements à convenir avec le centre. Pour un besoin d'accessibilité, décrivez le besoin pratique sans diagnostic médical.

Programme enrichi proposé, à valider par le formateur avant animation. Les approfondissements sont adaptés au niveau et au temps disponible. Aucune certification professionnelle ni prise en charge CPF ou OPCO n'est garantie. Démarche Qualiopi en cours ; certification non acquise.

Références pour approfondir

- [scikit-learn](#) · [pièges méthodologiques](#)