

PROGRAMME DE FORMATION · VERSION 3 · 2026-09-13

LLMOps : deployer, observer et gouverner les applications LLM

Construisez un dispositif de livraison pour une application LLM : jeux d'évaluation, traces exploitables, budgets d'usage et décisions de mise en production. Le fil rouge relie chaque changement de prompt à une mesure et à un scénario de retour arrière.

2 jours · 14 heures

Avancé · Hybride

2 190 € HT

Tarif indicatif, dates, disponibilité et modalités contractuelles à confirmer avec le centre.

À qui s'adresse cette formation ?

Architectes IA, ML engineers, data scientists, responsables innovation et platform teams.

Prérequis

Connaissance des usages LLM, du machine learning ou des architectures IA.

Objectifs pédagogiques

- Comprendre les pratiques LLMOps et leurs enjeux
- Mettre en place evaluation, monitoring et versioning
- Anticiper les enjeux de cout, qualite et securite a l'echelle

Le cas fil rouge

Mettre en exploitation un assistant documentaire interne et décider si une nouvelle version peut remplacer la précédente.

Préparation

Python, requêtes HTTP et notions de RAG ; environnement de démonstration avec réponses enregistrées, sans abonnement obligatoire.

Progression détaillée

Répartition pédagogique proposée sur une base de 7 heures par jour, pauses exclues. À ajuster avec le formateur au positionnement initial. Les approfondissements « Pour aller plus loin » sont sélectionnés par le formateur selon le positionnement et le temps disponible ; ils ne constituent pas des heures supplémentaires garanties.

Jour 1 · 7 heures

1. Définir la qualité attendue d'une application LLM

210 minutes · apports, exercice et retour

- Décomposer modèle, prompt, corpus, outils et règles métier.
- Construire un jeu de questions représentatif, avec réponses attendues et cas sans réponse.

- Distinguer exactitude, fidélité aux sources, utilité et sécurité.
- Mesurer séparément la pertinence du retrieval, la fidélité des réponses et la capacité à refuser une question hors périmètre.

NOTIONS ET MÉTHODES EN DÉTAIL

- Séparer exactitude factuelle, fidélité documentaire et utilité métier ; définir réponse acceptable et refus attendu.
- Constituer un jeu de référence : demandes simples, ambiguës, sans réponse et tentatives de détournement.
- Comparer annotation humaine, métriques et juge LLM ; repérer biais de position et désaccords.

Atelier prévu

Écrire vingt cas de recette pour un assistant de procédures, dont cinq cas ambigus ou adverses, et préciser les critères d'acceptation.

Livrable attendu

Jeu de recette annoté, taxonomie des erreurs et seuils de blocage.

Vérification en atelier

La grille distingue défaut de récupération, erreur de réponse et refus injustifié.

Pour aller plus loin · selon positionnement et temps disponible

Concevoir une recette stratifiée par population, niveau de risque et type de document ; analyser les écarts entre moyenne globale et segments.

2. Versionner et comparer les expériences

210 minutes · apports, exercice et retour

- Versionner prompts, paramètres, documents et jeux d'évaluation ensemble.
- Comparer une baseline et une variante sur les mêmes entrées.
- Calibrer un évaluateur automatique avec une revue humaine et rechercher ses biais.
- Fixer les versions du corpus, du découpage, des embeddings et des paramètres pour rendre une comparaison interprétable.

NOTIONS ET MÉTHODES EN DÉTAIL

- Versionner ensemble prompt, modèle, paramètres, index et configuration de récupération.
- Isoler un changement par expérience ; conserver entrées, résultats et règles de comparaison.
- Séparer jeu de développement et non-régression ; agréger les résultats par famille de questions.

Atelier prévu

Produire une matrice comparant deux versions ; documenter les régressions et les désaccords entre notes automatiques et jugement humain.

Livrable attendu

Matrice d'expériences avec paramètres, résultats par segment et décision motivée.

Vérification en atelier

Deux versions sont comparées sans mélanger documents ou paramètres.

Pour aller plus loin · selon positionnement et temps disponible

Comparer plusieurs exécutions d'un même scénario, calibrer les évaluateurs et expliquer pourquoi un gain moyen peut masquer une régression critique.

Jour 2 · 7 heures

3. Observer les appels et contenir les incidents

210 minutes · apports, exercice et retour

- Tracer latence, consommation, erreurs, retrieval et appels d'outils.
- Masquer les données sensibles dans les traces et fixer leur conservation.
- Définir budgets, quotas, délais d'attente, reprise et circuit de secours.
- Relier un identifiant de requête aux étapes retrieval, génération et outils ; distinguer latence au premier jeton, latence totale et échecs de dépendances.

NOTIONS ET MÉTHODES EN DÉTAIL

- Décomposer recherche, premier token et génération ; analyser percentiles de latence et coût par requête utile.
- Corréler traces et identifiants techniques en masquant données personnelles et extraits sensibles.
- Fixer plafonds de tokens, délais, limitation de débit et réponse dégradée en cas de panne.

Atelier prévu

Analyser des traces synthétiques, localiser une hausse de coût et rédiger une alerte avec seuil, responsable et action attendue.

Livrable attendu

Tableau de supervision, budget par requête et fiche de réponse à incident.

Vérification en atelier

Une panne produit un repli contrôlé et une trace exploitable sans donnée sensible.

Pour aller plus loin · selon positionnement et temps disponible

Simuler saturation, expiration d'un fournisseur et réponse sensible ; arbitrer cache, quotas, coupe-circuit et dégradation du service.

4. Organiser une livraison contrôlée

210 minutes · apports, exercice et retour

- Séparer tests hors ligne, tests de charge et surveillance en service.
- Préparer validation, déploiement progressif et retour à la version précédente.
- Attribuer la responsabilité des incidents et de la revue périodique du corpus.
- Séparer critères de livraison, contrôles de sécurité, supervision métier et obligations de conservation des traces.

NOTIONS ET MÉTHODES EN DÉTAIL

- Construire une porte de livraison associant qualité, tests d'abus, coût et approbation responsable.
- Déployer progressivement, comparer les cohortes et fixer les conditions d'arrêt de l'expérience.
- Préparer retour au prompt, au modèle et à l'index précédents avec un responsable identifié.

Atelier prévu

Présenter un dossier de mise en service : résultats de recette, seuils de blocage, procédure de repli et estimation du coût par demande.

Livrable attendu

Dossier de mise en service avec responsabilités, preuves de recette et procédure de repli.

Vérification en atelier

La procédure rétablit une version connue et vérifie le service après retour arrière.

Pour aller plus loin · selon positionnement et temps disponible

Préparer un déploiement canari avec seuils d'arrêt, procédure de retour arrière et revalidation après changement du corpus.

Évaluation finale

Mise en situation individuelle et restitution commentée, incluses dans la dernière séquence. Durée indicative : 60 minutes.

- Chaque décision de livraison cite une mesure reproductible.
- Les cas sans réponse et les risques de divulgation sont couverts.
- Une régression déclenche une action et un responsable identifiés.

Méthodes et ressources

Apports illustrés, exercices progressifs, ateliers sur un cas fil rouge et retour argumenté sur les productions. Les ateliers et l'évaluation font partie des heures indiquées.

Les ateliers décrivent les travaux prévus. Leurs fichiers, corrigés et évaluations en ligne sont à préparer, sauf ressources explicitement disponibles dans le module pilote.

Accès, accompagnement et contact

Pour obtenir plus de détails ou le programme détaillé validé, contactez le centre : 09 54 70 23 80 — contact@beyondexpertise.eu.

Positionnement et vérification des prérequis avant inscription. Délais, calendrier et aménagements à convenir avec le centre. Pour un besoin d'accessibilité, décrivez le besoin pratique sans diagnostic médical.

Programme enrichi proposé, à valider par le formateur avant animation. Les approfondissements sont adaptés au niveau et au temps disponible. Aucune certification professionnelle ni prise en charge CPF ou OPCO n'est garantie. Démarche Qualiopi en cours ; certification non acquise.

Références pour approfondir

- OWASP · sécurité des applications LLM
- MLflow · cycle de vie des modèles