

PROGRAMME DE FORMATION · VERSION 3 · 2026-09-13

Machine Learning pour Data Scientist Junior

Réalisez un premier projet supervisé de bout en bout avec un protocole d'évaluation solide. Le parcours relie cadrage, préparation, modèles de référence, analyse des erreurs et présentation des limites.

4 jours · 28 heures

Intermédiaire · Hybride

2 290 € HT

Tarif indicatif, dates, disponibilité et modalités contractuelles à confirmer avec le centre.

À qui s'adresse cette formation ?

Juniors data scientists, data analysts techniques, profils en montée de compétence vers la data science.

Prérequis

Connaître Python, les bases statistiques et la manipulation de données.

Objectifs pédagogiques

- Construire un premier pipeline de machine learning supervisé
- Comparer des modèles et interpréter leurs résultats
- Éviter les erreurs classiques de cadrage et d'évaluation

Le cas fil rouge

Réaliser un premier projet supervisé de bout en bout, en comparant modèles simples, métriques et limites sur un cas client fictif.

Préparation

Python, pandas et statistiques élémentaires ; notebook scikit-learn, données fictives et environnement préparé.

Progression détaillée

Répartition pédagogique proposée sur une base de 7 heures par jour, pauses exclues. À ajuster avec le formateur au positionnement initial. Les approfondissements « Pour aller plus loin » sont sélectionnés par le formateur selon le positionnement et le temps disponible ; ils ne constituent pas des heures supplémentaires garanties.

Jour 1 · 7 heures

1. Formuler le problème supervisé

210 minutes · apports, exercice et retour

- Distinguer classification et régression.
- Définir cible, unité d'observation et décision métier.
- Construire une baseline et préciser le coût des erreurs.
- Identifier les observations censurées, les labels issus d'anciennes décisions et les délais d'obtention de la cible ; expliciter leurs conséquences sur le problème.

NOTIONS ET MÉTHODES EN DÉTAIL

- Définir cible, population, moment de prédiction et décision à soutenir.
- Comparer classification et régression selon la variable à prédire.
- Choisir métrique et baseline à partir du coût métier des erreurs.

Atelier prévu

Transformer une demande de score client en problème testable avec horizon, population et métrique principale.

Livrable attendu

Cadrage du problème et critères de succès.

Vérification en atelier

La cible et les informations disponibles au moment de la prédiction sont explicites.

Pour aller plus loin · selon positionnement et temps disponible

Identifier une tâche qui semble supervisée mais ne possède pas de cible fiable.

2. Explorer et découper les données

210 minutes · apports, exercice et retour

- Examiner types, distributions et données manquantes.
- Séparer entraînement, validation et test selon temps ou groupes.
- Repérer doublons et informations fuyant la cible.
- Explorer déséquilibre, valeurs absentes et groupes ; choisir séparation aléatoire, temporelle ou groupée.

NOTIONS ET MÉTHODES EN DÉTAIL

- Examiner distributions, valeurs manquantes, doublons et déséquilibre des classes.
- Choisir découpage aléatoire, temporel ou par groupe selon les dépendances des données.
- Réserver le test final avant de régler les transformations.

Atelier prévu

Construire le découpage et vérifier qu'un même client ne se retrouve pas artificiellement dans plusieurs ensembles.

Livrable attendu

Audit exploratoire et découpage justifié.

Vérification en atelier

Le découpage évite qu'une même entité ou une information future traverse les ensembles.

Pour aller plus loin · selon positionnement et temps disponible

Repérer la présence d'un même individu dans apprentissage et test.

Jour 2 · 7 heures

3. Préparer un pipeline de données

210 minutes · apports, exercice et retour

- Imputer, encoder et mettre à l'échelle si nécessaire.
- Apprendre les transformations uniquement sur l'entraînement.

- Préparer gestion des catégories inconnues.
- Intégrer imputation, encodage et normalisation dans un pipeline sans fuite.

NOTIONS ET MÉTHODES EN DÉTAIL

- Associer imputation, encodage et mise à l'échelle aux types de colonnes.
- Utiliser Pipeline et ColumnTransformer pour ajuster uniquement sur l'apprentissage.
- Traiter catégories inconnues et colonnes invalides lors de l'inférence.

Atelier prévu

Créer un pipeline capable de traiter un nouvel exemple sans reproduire manuellement les transformations.

Livrable attendu

Pipeline de préparation et contrôles de schéma.

Vérification en atelier

Le même pipeline transforme apprentissage et nouvelles observations sans fuite.

Pour aller plus loin · selon positionnement et temps disponible

Tester catégories inconnues et colonnes manquantes à l'utilisation.

4. Entraîner les premiers modèles

210 minutes · apports, exercice et retour

- Comprendre régression linéaire ou logistique et arbres.
- Comparer baseline, modèle linéaire et ensemble d'arbres.
- Lire paramètres et premiers signes de surapprentissage.
- Comparer capacité de généralisation et courbes d'apprentissage ; examiner les effets de régularisation, profondeur et déséquilibre des classes.

NOTIONS ET MÉTHODES EN DÉTAIL

- Comparer régression linéaire ou logistique et arbre de décision selon la cible.
- Observer effet de profondeur, régularisation et mise à l'échelle.
- Conserver paramètres et résultats sur le même protocole.

Atelier prévu

Entraîner trois modèles avec les mêmes données et enregistrer temps, métriques et configuration.

Livrable attendu

Tableau comparatif et choix initial.

Vérification en atelier

Le modèle retenu est comparé à une baseline simple et reproductible.

Pour aller plus loin · selon positionnement et temps disponible

Expliquer pourquoi un modèle plus complexe n'améliore pas la référence.

Jour 3 · 7 heures

5. Évaluer les erreurs

210 minutes · apports, exercice et retour

- Lire matrice de confusion ou distribution des résidus.
- Choisir métriques adaptées au déséquilibre et au coût métier.
- Examiner résultats par segments avec prudence.
- Analyser matrice de confusion, erreurs par segment, seuil et calibration selon la tâche.

NOTIONS ET MÉTHODES EN DÉTAIL

- Lire confusion, précision, rappel ou résidus selon le problème.
- Examiner erreurs par segment et situations de faible fiabilité.
- Distinguer score moyen et conséquence d'une erreur sur un cas critique.

Atelier prévu

Analyser les erreurs les plus coûteuses et proposer un seuil compatible avec la capacité d'action métier.

Livrable attendu

Rapport d'erreurs et seuil argumenté.

Vérification en atelier

Le rapport décrit des erreurs concrètes et leur impact métier.

Pour aller plus loin · selon positionnement et temps disponible

Choisir un seuil en tenant compte du coût des faux positifs et faux négatifs.

6. Améliorer sans surajuster

210 minutes · apports, exercice et retour

- Utiliser validation croisée adaptée aux données.
- Régler quelques hyperparamètres avec budget limité.
- Conserver le test final pour l'évaluation de la solution retenue.
- Encadrer validation croisée, recherche d'hyperparamètres et conservation d'un test final.

NOTIONS ET MÉTHODES EN DÉTAIL

- Utiliser validation croisée adaptée et recherche limitée d'hyperparamètres.
- Comparer stabilité et écart apprentissage-validation.
- Éviter de consulter répétitivement le test final pour choisir les paramètres.

Atelier prévu

Comparer des candidats en validation et justifier le choix d'un modèle plus simple lorsque le gain complexe reste faible.

Livrable attendu

Protocole d'optimisation et résultats validés.

Vérification en atelier

La sélection est fondée sur validation et le test reste réservé au bilan.

Pour aller plus loin · selon positionnement et temps disponible

Détecter un ajustement répété sur le jeu de test qui invalide la conclusion.

Jour 4 · 7 heures

7. Interpréter et préparer la réutilisation

210 minutes · apports, exercice et retour

- Décrire les variables influentes sans en déduire une causalité.
- Enregistrer le pipeline et son environnement.
- Définir contrat d'entrée et contrôles de qualité.
- Expliquer effets des variables avec prudence ; documenter limites et domaine d'utilisation.

NOTIONS ET MÉTHODES EN DÉTAIL

- Examiner importance des variables et limites de l'interprétation causale.
- Enregistrer pipeline, schéma d'entrée et version des dépendances.
- Tester rechargement et prédiction sur un petit jeu de référence.

Atelier prévu

Recharger le pipeline dans une session propre et produire des prédictions sur un lot nouveau.

Livrable attendu

Fiche modèle et analyse des limites.

Vérification en atelier

Le modèle rechargé reproduit les résultats attendus sans préparation manuelle cachée.

Pour aller plus loin · selon positionnement et temps disponible

Vérifier stabilité d'une explication entre échantillons et variables corrélées.

8. Présenter le projet et ses limites

210 minutes · apports, exercice et retour

- Restituer problème, protocole, résultats et erreurs.
- Documenter périmètre, risques et surveillance nécessaire.
- Proposer les prochaines données ou expériences utiles.
- Présenter problème, données, baseline, résultats, risques et prochaine décision.

NOTIONS ET MÉTHODES EN DÉTAIL

- Présenter problème, données, méthode, résultats et limites dans un dossier cohérent.
- Proposer contrôles avant utilisation réelle et critères de surveillance.
- Distinguer démonstrateur pédagogique et service opérationnel prêt à déployer.

Atelier prévu

Présenter un dossier de projet avec notebook reproductible, comparaison à la baseline et fiche modèle argumentée.

Livrable attendu

Dossier final et soutenance argumentée.

Vérification en atelier

La soutenance justifie les choix et reconnaît les conditions où le modèle ne convient pas.

Pour aller plus loin · selon positionnement et temps disponible

Défendre un choix simple et robuste face à une demande de meilleur score seul.

Évaluation finale

Mise en situation individuelle et restitution commentée, incluses dans la dernière séquence. Durée indicative : 60 minutes.

- Le protocole évite les fuites et l'usage répété du test final.
- Le modèle est comparé à une baseline.
- La restitution explique les erreurs et le domaine d'utilisation.

Méthodes et ressources

Apports illustrés, exercices progressifs, ateliers sur un cas fil rouge et retour argumenté sur les productions. Les ateliers et l'évaluation font partie des heures indiquées.

Les ateliers décrivent les travaux prévus. Leurs fichiers, corrigés et évaluations en ligne sont à préparer, sauf ressources explicitement disponibles dans le module pilote.

Accès, accompagnement et contact

Pour obtenir plus de détails ou le programme détaillé validé, contactez le centre : 09 54 70 23 80 — contact@beyondexpertise.eu.

Positionnement et vérification des prérequis avant inscription. Délais, calendrier et aménagements à convenir avec le centre. Pour un besoin d'accessibilité, décrivez le besoin pratique sans diagnostic médical.

Programme enrichi proposé, à valider par le formateur avant animation. Les approfondissements sont adaptés au niveau et au temps disponible. Aucune certification professionnelle ni prise en charge CPF ou OPCO n'est garantie. Démarche Qualiopi en cours ; certification non acquise.

Références pour approfondir

- [scikit-learn](#) · pièges méthodologiques