

PROGRAMME DE FORMATION · VERSION 3 · 2026-09-13

# RAG et bases vectorielles pour l'entreprise

Construisez une recherche documentaire augmentée qui restitue des réponses vérifiables. Le parcours couvre préparation du corpus, indexation, filtrage des accès, récupération et évaluation des erreurs de recherche ou de génération.

2 jours · 14 heures

Avancé · Hybride

1 990 € HT

Tarif indicatif, dates, disponibilité et modalités contractuelles à confirmer avec le centre.

## À qui s'adresse cette formation ?

Architectes data, responsables innovation, développeurs IA, chefs de projet transformation.

### Prérequis

Connaître les bases des systèmes d'information et des usages IA générative.

## Objectifs pédagogiques

- Comprendre les composants d'une architecture RAG
- Identifier les cas d'usage métier les plus pertinents
- Anticiper les enjeux de qualité, de sécurité et de gouvernance

## Le cas fil rouge

Concevoir un assistant de recherche dans des procédures d'entreprise et évaluer la pertinence des documents retrouvés avant la réponse générée.

### Préparation

Bases d'architecture SI et d'IA générative ; corpus fictif, notebook ou démonstration RAG, API simulée possible.

## Progression détaillée

Répartition pédagogique proposée sur une base de 7 heures par jour, pauses exclues. À ajuster avec le formateur au positionnement initial. Les approfondissements « Pour aller plus loin » sont sélectionnés par le formateur selon le positionnement et le temps disponible ; ils ne constituent pas des heures supplémentaires garanties.

## Jour 1 · 7 heures

### 1. Décomposer une architecture RAG

210 minutes · apports, exercice et retour

- Distinguer ingestion, indexation, recherche et génération.
- Comparer recherche lexicale, vectorielle et hybride.
- Définir questions métier et sources de référence attendues.
- Relier ingestion, découpage, embeddings, recherche, contexte et génération ; définir une baseline.

## NOTIONS ET MÉTHODES EN DÉTAIL

- Séparer ingestion, découpage, embeddings, recherche, contexte et réponse.
- Distinguer index vectoriel et source documentaire de référence.
- Définir questions couvertes, sources autorisées et situations d'abstention.

### Atelier prévu

Dessiner l'architecture d'un assistant de procédures et préparer dix questions, dont deux sans réponse dans le corpus.

### Livrable attendu

Architecture RAG et contrat de réponse.

### Vérification en atelier

L'architecture peut expliquer d'où provient chaque information restituée.

Pour aller plus loin · selon positionnement et temps disponible

Comparer recherche documentaire seule et réponse générée selon besoin utilisateur.

## 2. Préparer documents et index

210 minutes · apports, exercice et retour

- Extraire texte, structure et métadonnées sans perdre le contexte.
- Comparer découpages, embeddings et index avec critères explicites.
- Prévoir mise à jour, suppression et propagation des droits.
- Choisir taille des segments, métadonnées, recherche hybride et filtrage selon les documents.

## NOTIONS ET MÉTHODES EN DÉTAIL

- Comparer découpage fixe et découpage par structure en conservant titre et provenance.
- Associer identifiant, version et droits d'accès aux fragments.
- Tester mise à jour et retrait d'un document sans conserver un doublon obsolète.

### Atelier prévu

Comparer deux découpages d'un même dossier et vérifier quels passages restent interprétables hors de leur document complet.

### Livrable attendu

Pipeline d'indexation et règles d'accès.

### Vérification en atelier

L'index retrouve la version valide et exclut un document retiré.

Pour aller plus loin · selon positionnement et temps disponible

Préserver les droits d'accès lors de l'indexation et de la recherche.

## Jour 2 · 7 heures

### 3. Construire une réponse vérifiable

210 minutes · apports, exercice et retour

- Filtrer les documents selon les droits avant restitution.

- Sélectionner et éventuellement réordonner les passages pertinents.
- Demander citations et abstention en cas de source insuffisante.
- Construire contexte, citations, refus en absence de preuve et protection contre instructions documentaires.

#### NOTIONS ET MÉTHODES EN DÉTAIL

- Comparer recherche lexicale, vectorielle et combinaison sur un jeu de questions.
- Examiner filtrage, top-k et réordonnement selon pertinence et coût.
- Demander réponse bornée aux passages avec citations et refus si la source manque.

#### Atelier prévu

Tester l'assistant sur question ambiguë, document obsolète et instruction hostile dans une source, puis examiner les références affichées.

#### Livrable attendu

Réponse sourcée et scénarios de refus.

#### Vérification en atelier

La réponse ne transforme pas un passage non pertinent en preuve.

#### Pour aller plus loin · selon positionnement et temps disponible

Traiter deux sources contradictoires sans produire une synthèse faussement certaine.

## 4. Évaluer qualité et exploitation

210 minutes · apports, exercice et retour

- Séparer qualité de retrieval et fidélité de la réponse.
- Mesurer couverture, pertinence, latence et coût sur un jeu fixe.
- Planifier surveillance du corpus et traitement des retours utilisateurs.
- Séparer rappel de recherche, pertinence, fidélité, latence et coût ; versionner corpus et tests.

#### NOTIONS ET MÉTHODES EN DÉTAIL

- Séparer mesure de récupération et fidélité de la réponse aux documents.
- Tester question ambiguë, corpus contradictoire et instruction hostile dans un document.
- Suivre latence, coût et accès sans conserver inutilement les requêtes personnelles.

#### Atelier prévu

Livrer une matrice de recette et une recommandation d'architecture justifiée par les résultats, avec limites et actions correctives.

#### Livrable attendu

Banc d'évaluation et plan d'exploitation.

#### Vérification en atelier

Le rapport localise l'erreur dans la recherche ou dans la restitution.

#### Pour aller plus loin · selon positionnement et temps disponible

Diagnostiquer une réponse erronée en localisant recherche, contexte ou génération.

## Évaluation finale

Mise en situation individuelle et restitution commentée, incluses dans la dernière séquence. Durée indicative : 60 minutes.

- Les citations soutiennent réellement les réponses.
- Les droits sont respectés au niveau de la recherche.
- Les erreurs de retrieval sont distinguées des erreurs de génération.

## Méthodes et ressources

Apports illustrés, exercices progressifs, ateliers sur un cas fil rouge et retour argumenté sur les productions. Les ateliers et l'évaluation font partie des heures indiquées.

Les ateliers décrivent les travaux prévus. Leurs fichiers, corrigés et évaluations en ligne sont à préparer, sauf ressources explicitement disponibles dans le module pilote.

## Accès, accompagnement et contact

Pour obtenir plus de détails ou le programme détaillé validé, contactez le centre : 09 54 70 23 80 — [contact@beyondexpertise.eu](mailto:contact@beyondexpertise.eu).

Positionnement et vérification des prérequis avant inscription. Délais, calendrier et aménagements à convenir avec le centre. Pour un besoin d'accessibilité, décrivez le besoin pratique sans diagnostic médical.

Programme enrichi proposé, à valider par le formateur avant animation. Les approfondissements sont adaptés au niveau et au temps disponible. Aucune certification professionnelle ni prise en charge CPF ou OPCO n'est garantie. Démarche Qualiopi en cours ; certification non acquise.

## Références pour approfondir

- OWASP · sécurité des applications LLM
- Databricks · architecture lakehouse